

Sistema de Reconocimiento de Actividades Humanas mediante Análisis de Poses y Reducción de Dimensionalidad Biomecánica

Kevin Steven Nieto Curaca

Código: A00395466

Universidad ICESI

Cali, Colombia

kevin.nieto@u.icesi.edu.co

Ricardo Urbina Ospina

Código: A00395489

Universidad ICESI

Cali, Colombia

ricardo.urbina@u.icesi.edu.co

Julian Mendoza

Código: A00395237

Universidad ICESI

Cali, Colombia

julian.mendoza@u.icesi.edu.co

Resumen—Este documento presenta el desarrollo y evolución de un sistema de reconocimiento de actividades humanas (HAR) orientado a la clasificación de siete movimientos específicos, incluyendo transiciones posturales y locomoción. El estudio aborda la problemática de la alta dimensionalidad en el análisis de video mediante una estrategia de ingeniería de características basada en principios biomecánicos. Se describe la transición desde un enfoque inicial complejo utilizando LSTM bidireccionales con más de 35 variables, hacia una solución optimizada que emplea un vector de 7 características ortogonales (invariantes a la escala y perspectiva). Se comparan dos metodologías finales: una basada en redes neuronales recurrentes (LSTM) con ventana deslizante y otra basada en algoritmos de boosting (XGBoost), evaluadas sobre un dataset heterogéneo compuesto por tres fuentes de video con variabilidad controlada.

Index Terms—HAR, LSTM, XGBoost, MediaPipe, Ingeniería de Características, Biomecánica Computacional.

I. INTRODUCCIÓN

El reconocimiento de actividades humanas (HAR) es un campo fundamental en la visión por computadora con aplicaciones críticas en vigilancia, salud y rehabilitación. Sin embargo, el procesamiento de secuencias de video crudas presenta desafíos significativos debido a la variabilidad intraclass y la "maldición de la dimensionalidad".

El presente proyecto tiene como finalidad desarrollar un sistema robusto capaz de clasificar movimientos como *sitting down*, *standing up*, *walking towards/away*, *turning* y estados estáticos. La hipótesis central del trabajo es que la reducción de dimensionalidad basada en la física del movimiento humano (ángulos y vectores normalizados) permite modelos más ligeros y generalizables que aquellos alimentados con coordenadas crudas.

II. OBJETIVOS

II-A. Objetivo General

Desarrollar un sistema de datos y clasificación eficiente orientado al reconocimiento de siete movimientos humanos específicos:

- SITTING_DOWN (sentarse)
- STANDING_UP (levantarse)

- WALKING_TOWARDS_CAMERA (caminar hacia la cámara)
- WALKING_AWAY_FROM_CAMERA (alejarse de la cámara)
- TURNING (girar)
- STANDING_STILL (estar de pie estático)
- SITTING_STILL (estar sentado estático)

El sistema busca optimizar la relación entre la complejidad del modelo y la precisión mediante la ingeniería de características biomecánicas.

II-B. Objetivos Específicos

- Implementar un pipeline de extracción de esqueletos utilizando MediaPipe para la obtención de *World Landmarks*.
- Establecer una estrategia de etiquetado rigurosa utilizando la herramienta **Label Studio**. Se definió una configuración de *TimelineLabels* para la anotación de segmentos múltiples (*Multiple Segments*), permitiendo asignar etiquetas temporales precisas a cada flujo de video.
- Diseñar un vector de características que garantice invarianza de escala y rotación.
- Comparar el desempeño de arquitecturas de aprendizaje profundo secuencial (LSTM) frente a métodos de ensamble (XGBoost) utilizando múltiples fuentes de datos.

III. MARCO TEÓRICO

III-A. Extracción de Poses: MediaPipe

Se utiliza el framework MediaPipe Pose para la detección de 33 puntos clave corporales. Una distinción crítica en este proyecto es el uso de **World Landmarks** frente a los landmarks normalizados de pantalla. Los *World Landmarks* proporcionan coordenadas métricas en 3D (en metros) con el origen (0,0,0) situado en el centro de la cadera del sujeto. Esto es fundamental matemáticamente, ya que desacopla la acción biomecánica de la posición absoluta del sujeto en la habitación, permitiendo calcular vectores relativos al centro de masa.




Figura 1. Landmarks definidos por mediapipe en total son 33 puntos.

III-B. Modelos de Clasificación

III-B1. LSTM (Long Short-Term Memory): Redes neuronales recurrentes diseñadas para mitigar el problema del desvanecimiento del gradiente, capaces de aprender dependencias a largo plazo en series temporales, ideales para capturar la evolución temporal de un movimiento.

III-B2. XGBoost: Un algoritmo de aprendizaje supervisado basado en árboles de decisión y *gradient boosting*. Se utiliza en la etapa final del proyecto para evaluar si las características extraídas son lo suficientemente discriminantes por sí solas sin depender excesivamente de la recurrencia profunda.

III-C. Herramientas de Etiquetado

Se empleó Label Studio para la anotación temporal precisa de los videos, permitiendo segmentar los flujos continuos de video en las 7 clases objetivo y generar los archivos JSON de entrenamiento.

El sistema Label Studio facilita la definición personalizada de etiquetas labels asociadas a cada cuadro (*frame*) de un video mediante el establecimiento de una tasa de cuadros por segundo (*fps*).

Resulta fundamental la correcta especificación de este parámetro *fps*, ya que su valor es posteriormente empleado para delimitar los segmentos temporales específicos del video donde se desarrolla una acción. Esta delimitación es crucial para la validación y trazabilidad de los datos utilizados en el proceso de anotación.

Para la implementación de la anotación de actividad en segmentos múltiples, se requiere una configuración específica en formato XML. A continuación, se presenta un ejemplo donde se muestran las diferentes labels disponibles para el vídeo en cuestión:




Figura 2. Captura de uso de label studio con las labels definidas

IV. DESCRIPCIÓN DE LOS DATOS (SOURCES)

Para garantizar la robustez del modelo, se construyó un dataset compuesto por tres fuentes distintas (*Sources*), cada una aportando variabilidad específica:

Cuadro I
DESCRIPCIÓN DE LAS FUENTES DE DATOS

Fuente	Características
Source 1	≈ 18 videos de 10 sujetos realizando ciclos completos de pararse, acercarse a cámara, girar y sentarse. Representa variabilidad de sujetos.
Source 2	22 Videos similares a la Source 1 pero con variaciones en la ejecución, incluyendo inclinaciones y ruido postural.
Source 3	10 Videos segmentados por tipo de actividad específica (ej. caminar rápido/lento, sentarse rápido/lento). Aporta variabilidad en velocidad de ejecución.

V. INGENIERÍA DE CARACTERÍSTICAS

Tras una primera iteración con 39 variables que resultó en complejidad computacional innecesaria, se redujo el sistema a 7 características ortogonales basadas en principios geométricos.

V-A. Invarianza de Escala: L_{norm}

La Longitud de Pierna Normalizada se define para eliminar la variable de la "altura del usuario".

$$L_{norm} = \frac{d(P_{cad}, P_{tob})}{d(P_{cad}, P_{rod}) + d(P_{rod}, P_{tob})} \quad (1)$$

Donde P son los puntos de cadera, rodilla y tobillo.

- **Valor Matemático:** Representa la desigualdad triangular. En postura de pie, $L_{norm} \approx 1$. Al sentarse, se forma un vértice en la rodilla, resultando en $L_{norm} \ll 1$.

V-B. Análisis Vectorial (Plano XZ)

Se utilizan proyecciones en el plano transversal (suelo) ignorando el componente Y para detectar orientación.

V-B1. Vector de Hombros: Detecta la orientación del torso superior:

$$\vec{v}_{hombros} = \text{norm}(\Pi_{xz}(P_{HombroR} - P_{HombroL})) \quad (2)$$

V-B2. *Vector de Tobillos*: Característica crítica para discriminar marcha y giro. Su cálculo implica:

1. Diferencia vectorial relativa a la cadera: $\vec{v}_{raw} = P_{TobilloR} - P_{TobilloL}$.
2. Proyección ortogonal eliminando la altura: $\vec{v}_{xz} = [v_{raw_x}, 0, v_{raw_z}]$.
3. Normalización unitaria.

La discrepancia angular entre $\vec{v}_{hombros}$ y $\vec{v}_{tobillos}$ es el predictor matemático más fuerte para la clase *Turning* (desacople de torsión). Además de permitirnos comprender la dirección del vector generado por los tobillos, el cual varía en función del movimiento oscilante de las piernas de las personas.

V-C. Cinemática Angular

Ángulos promedio de cadera y rodilla calculados mediante producto punto. Actúan como discriminadores no lineales donde *Sitting Down* es una función decreciente de $\theta_{rodilla}$ ($180^\circ \rightarrow 90^\circ$). Lo que permite distinguir fácilmente entre si un persona está parada, sentanda o en proceso de llegar a alguna de las 2 nombradas.

VI. METODOLOGÍA Y RESULTADOS

VI-A. Iteración 1: Exploración de Características y Diagnóstico de Overfitting

En esta primera fase, se desarrolló un modelo experimental con el objetivo principal de validar la ingeniería de características y comprender qué variables biomecánicas eran determinantes para la clasificación. Se utilizó el dataset inicial de 53 videos (*source-1*) bajo condiciones controladas.

Metodología y Alta Dimensionalidad: Se diseñó un espacio de características extenso, generando inicialmente 50 descriptores por frame. Tras una eliminación básica de varianza nula, se entrenó un modelo LSTM bidireccional utilizando un conjunto denso de **39 features** (incluyendo múltiples ángulos, velocidades y ratios). El objetivo era saturar al modelo de información para observar su comportamiento límite.

Resultados y Análisis de Overfitting: El modelo obtuvo métricas perfectas en validación y test (*Accuracy*: 100 %, *Loss*: ~ 0.01). Lejos de considerarse un éxito final, este resultado se interpretó como un caso de **overfitting** contextual. La alta dimensionalidad (39 features) permitió al modelo memorizar patrones específicos de los sujetos y las condiciones de grabación del dataset pequeño, comprometiendo su capacidad de generalización ante nuevos entornos.

Contribución al Refinamiento: A pesar del sobreajuste, esta iteración cumplió un rol fundamental como "laboratorio de características". Al analizar los pesos y la influencia de cada variable en este modelo "perfecto", se logró discriminar entre señal y ruido. Esto permitió identificar que gran parte de las 39 features eran redundantes, sentando la base empírica para la limpieza agresiva y la selección de las características verdaderamente discriminantes que se utilizarían en la Iteración 2.

VI-B. Iteración 2: LSTM con Ventana Deslizante y Features Reducidas

Se implementó una nueva arquitectura optimizada con las 7 features descritas.

VI-B1. *Arquitectura de Red*: Se diseñó una estructura jerárquica de embudo para comprimir información temporal:

- **Entrada:** Ventana deslizante de (30, 7), equivalente a 1 segundo de contexto.
- **LSTM 1:** 128 unidades (extracción de patrones crudos).
- **LSTM 2:** 64 unidades (abstracción).
- **Clasificación:** Capa densa de 32 unidades seguida de Softmax.

VI-B2. *Estrategia de Regularización:* Dada la baja dimensionalidad, se aplicó un *Dropout* agresivo (0.3 en LSTM, 0.2 recurrente) para evitar memorización. El entrenamiento utilizó *Early Stopping* (paciencia 15) y reducción de *Learning Rate* en mesetas.

Resultados Iteración 2:

A pesar de la depuración de datos y la reducción de dimensionalidad, los resultados obtenidos en esta fase fueron decepcionantes. El modelo alcanzó una precisión global de apenas el **44 %**. Este bajo rendimiento evidenció que, aunque las características eran geométricamente robustas, la red recurrente no logró capturar eficazmente las dependencias temporales complejas necesarias para discriminar entre las clases dinámicas y estáticas bajo esta configuración específica.




Figura 3. Review de resultados para LSTM iteración 2.




Figura 4. Matriz de confusión para la iteración 2 con LSTM

VI-C. Iteración 3: Enfoque Multi-Source con XGBoost

Finalmente, se integraron las fuentes de datos disponibles y se evaluó el rendimiento utilizando XGBoost. Este enfoque busca validar si las 7 features biomecánicas son lo suficientemente robustas para clasificación clásica sin la complejidad computacional de las redes recurrentes.

VI-C1. Configuración del Dataset: Inicialmente se planificó utilizar las 3 fuentes de datos (source1, source2 y source3). Sin embargo, durante el proceso de entrenamiento se identificó que source2 presentaba problemas de calidad o consistencia en los datos etiquetados, por lo que se decidió excluir esta fuente del conjunto de entrenamiento final. Por lo tanto, el modelo XGBoost se entrenó utilizando únicamente source1 y source3, lo que resultó en un dataset más limpio y consistente.

Las 7 features biomecánicas utilizadas fueron:

- **normalized_leg_length:** Longitud normalizada de la pierna
- **shoulder_vector_x:** Componente X del vector de hombros
- **shoulder_vector_z:** Componente Z del vector de hombros
- **ankle_vector_x:** Componente X del vector de tobillos
- **ankle_vector_z:** Componente Z del vector de tobillos
- **average_hip_angle:** Ángulo promedio de cadera
- **average_knee_angle:** Ángulo promedio de rodilla

VI-C2. Optimización de Hiperparámetros: Para obtener la mejor configuración posible del modelo XGBoost, se implementó un script de búsqueda exhaustiva de hiperparámetros denominado *ultra_search*. Este script realizó una búsqueda aleatoria (random search) sobre un espacio de hiperparámetros definido, evaluando 200 combinaciones diferentes.

El espacio de búsqueda incluyó los siguientes parámetros:

- **n_estimators:** [500, 700, 1000, 1500] - Número de árboles
- **max_depth:** [6, 8, 10, 12] - Profundidad máxima de los árboles
- **learning_rate:** [0.01, 0.03, 0.05, 0.07] - Tasa de aprendizaje
- **min_child_weight:** [1, 3, 5, 7] - Peso mínimo de nodos hijos
- **subsample:** [0.8, 0.85, 0.9, 0.95] - Proporción de muestras por árbol
- **colsample_bytree:** [0.8, 0.85, 0.9, 0.95] - Proporción de features por árbol
- **reg_alpha:** [0.0, 0.1, 0.2, 0.3] - Regularización L1
- **reg_lambda:** [1.0, 1.5, 2.0, 3.0] - Regularización L2
- **gamma:** [0.0, 0.1, 0.2, 0.3] - Reducción mínima de pérdida para división
- **early_stopping_rounds:** [20, 30, 40, 50] - Rondas de parada temprana

La búsqueda se realizó durante aproximadamente 30 minutos, evaluando cada combinación en el conjunto de validación utilizando el F1-score ponderado como métrica principal. La mejor configuración encontrada fue:

```
n_estimators: 500
max_depth: 10
learning_rate: 0.07
min_child_weight: 1
subsample: 0.8
colsample_bytree: 0.9
reg_alpha: 0.3
reg_lambda: 2.0
gamma: 0.0
early_stopping_rounds: 20
```

VI-C3. Preprocesamiento y Entrenamiento: El pipeline de entrenamiento incluyó las siguientes optimizaciones:

- **Normalización de features:** Se aplicó *StandardScaler* para normalizar las features (media=0, desviación estándar=1)
- **Manejo de desbalance de clases:** Se calcularon pesos de clase balanceados y se aplicaron como *sample_weights* durante el entrenamiento
- **Early stopping:** Se implementó parada temprana con 20 rondas para prevenir sobreajuste
- **División estratificada:** Los datos se dividieron en 65 % entrenamiento, 15 % validación y 20 % prueba, manteniendo la distribución de clases

VI-C4. Resultados: El modelo XGBoost entrenado con los hiperparámetros optimizados alcanzó los siguientes resultados en el conjunto de prueba:

Métricas Globales:

- **Precisión (Accuracy):** 85.58 % (0.8558)
- **F1-Score Ponderado:** 85.32 % (0.8532)
- **Precisión Ponderada:** 85.49 % (0.8549)
- **Recall Ponderado:** 85.58 % (0.8558)

Métricas por Clase: El modelo mostró un rendimiento consistente en todas las clases, con F1-scores que oscilan entre 64.29 % para `standing_up` (la clase más desafiante) y 92.99 % para `walking_away_from_camera` (la mejor clasificada). Las métricas detalladas por clase se muestran en la Tabla II y en la Figura 6.

Cuadro II
MÉTRICAS POR CLASE — XGBOOST

Clase	Precisión	Recall	F1-Score	Soporte
sitting_down	80.33 %	81.67 %	80.99 %	60
sitting_still	82.86 %	92.06 %	87.22 %	63
standing_still	83.87 %	92.86 %	88.14 %	56
standing_up	72.00 %	58.06 %	64.29 %	62
turning	94.17 %	85.09 %	89.40 %	114
walking_away_from_camera	91.25 %	94.81 %	92.99 %	77
walking_towards_camera	85.15 %	90.53 %	87.76 %	95

La matriz de confusión (Figura 5) revela que el modelo tiene dificultades principalmente con la clase `standing_up`, que se confunde frecuentemente con `sitting_down` y `walking_towards_camera`, lo cual es esperable dado que estas transiciones comparten características biomecánicas similares.

VI-C5. Importancia de Features: El análisis de importancia de features (Figura 7) revela que las features más relevantes para la clasificación son:

1. `average_knee_angle`: Ángulo promedio de rodilla (mayor importancia)
2. `normalized_leg_length`: Longitud normalizada de la pierna
3. `average_hip_angle`: Ángulo promedio de cadera
4. `ankle_vector_z`: Componente Z del vector de tobillos
5. `shoulder_vector_x`: Componente X del vector de hombros
6. `ankle_vector_x`: Componente X del vector de tobillos
7. `shoulder_vector_z`: Componente Z del vector de hombros (menor importancia)

Este resultado valida que las features biomecánicas seleccionadas capturan información relevante para distinguir entre las diferentes actividades de movimiento.

VI-C6. Comparación de Rendimiento y Tiempos: En comparación con otros modelos evaluados:

- **vs. LSTM:** El modelo XGBoost supera significativamente al LSTM (44 % de precisión), lo que sugiere que para este dataset, las features biomecánicas estáticas son más efectivas que el modelado temporal secuencial.
- **vs. Random Forest:** El XGBoost muestra un rendimiento superior, aprovechando el gradient boosting para capturar relaciones no lineales más complejas.

Tiempos de Entrenamiento e Inferencia:

- **Búsqueda de hiperparámetros:** Aproximadamente 30 minutos para evaluar 200 combinaciones (promedio de 9 segundos por combinación)
- **Entrenamiento del modelo final:** Menos de 1 minuto con los hiperparámetros optimizados
- **Tiempo de inferencia:** Inferencia extremadamente rápida (microsegundos por frame), permitiendo procesamiento en tiempo real incluso en dispositivos con recursos limitados

Ventajas del enfoque XGBoost:

- **Inferencia rápida:** El tiempo de inferencia es significativamente menor que el de modelos recurrentes, permitiendo clasificación en tiempo real
- **Interpretabilidad:** La importancia de features proporciona insights sobre qué características biomecánicas son más relevantes
- **Eficiencia computacional:** El entrenamiento es más rápido y requiere menos recursos que las redes neuronales profundas
- **Robustez:** El modelo generaliza bien con un dataset relativamente pequeño
- **Escalabilidad:** Puede manejar grandes volúmenes de datos de manera eficiente

VI-C7. Visualizaciones: Las siguientes figuras muestran los resultados detallados del modelo XGBoost:




Figura 5. Matriz de confusión del modelo XGBoost

VI-C8. Conclusiones de la Iteración 3: La Iteración 3 demuestra que un enfoque clásico de machine learning con XGBoost puede alcanzar un rendimiento excelente (85.58 % de precisión) utilizando únicamente 7 features biomecánicas bien seleccionadas. La exclusión de `source2` mejoró la consistencia del dataset, y la optimización exhaustiva de hiperparámetros permitió encontrar una configuración óptima.




Figura 6. Métricas por clase del modelo XGBoost




Figura 7. Importancia de features del modelo XGBoost

El modelo XGBoost presenta ventajas significativas en términos de velocidad de inferencia y eficiencia computacional comparado con modelos recurrentes, mientras mantiene una alta precisión. Esto lo convierte en una solución práctica y escalable para clasificación de actividades de movimiento en tiempo real.

VII. COMPARATIVA DE RESULTADOS

Cuadro III
COMPARATIVA DE MODELOS

Métrica	LSTM (Iter 2)	XGBoost (Iter 3)
Precisión Global	44.00 %	85.58 %
F1-Score Ponderado	41.86 %	85.32 %
Clase Mejor Predicha	walking_towards_camera	walking_away_from_camera
Tiempo Entrenamiento	Alto (varias horas)	Bajo (<1 minuto)
Tiempo Inferencia	Medio (ms por secuencia)	Muy rápido (μs por frame)
Complejidad Computacional	Alta	Baja

Los resultados demuestran que el modelo XGBoost supera significativamente al LSTM en todas las métricas evaluadas.

Mientras que el LSTM alcanzó solo un 44 % de precisión, el XGBoost logró 85.58 %, casi duplicando el rendimiento.

Esta diferencia se atribuye principalmente a que las 7 features biomecánicas seleccionadas capturan de manera efectiva la información discriminativa necesaria para clasificar las actividades, sin requerir el modelado temporal complejo que ofrece el LSTM. El XGBoost aprovecha mejor las características estáticas y relativas del movimiento, especialmente en posturas estáticas y movimientos direccionales claros como `walking_away_from_camera` (92.99 % F1-score).

Aunque el LSTM teóricamente debería capturar mejor la temporalidad de transiciones como `sitting_down` y `standing_up`, el tamaño limitado del dataset y la calidad de las features biomecánicas permitieron que el XGBoost, con su capacidad de capturar relaciones no lineales complejas mediante gradient boosting, supere al modelo recurrente. Además, el XGBoost ofrece ventajas prácticas significativas: entrenamiento más rápido, inferencia en tiempo real y mayor interpretabilidad a través del análisis de importancia de features.

VIII. CONCLUSIÓN

La reducción de dimensionalidad de 35 a 7 características, fundamentada en vectores relativos a la cadera y proporciones antropométricas invariantes, demostró ser una estrategia exitosa. El uso de *World Landmarks* permitió desacoplar el movimiento de la posición global. Mientras que el modelo LSTM ofrece ventajas en transiciones dinámicas gracias a su memoria temporal, la ingeniería de características robusta permitió que algoritmos más ligeros como XGBoost obtuvieran resultados competitivos, validando la calidad de los datos extraídos.

Enlace al vídeo: <https://drive.google.com/drive/folders/1-s9iziLckqLYHwF1JKyaldv6Z-lRnRLe?usp=sharing>

REFERENCIAS

- [1] C. Lugaresi *et al.*, "MediaPipe: A Framework for Building Perception Pipelines," *ArXiv*, vol. abs/1906.08172, 2019. [Online]. Disponible: <https://arxiv.org/abs/1906.08172>
- [2] V. Bazarevsky, I. Grishchenko, K. Raveendran, T. Zhu, F. Zhang, y M. Grundmann, "BlazePose: On-device Real-time Body Pose tracking," *ArXiv*, vol. abs/2006.10204, 2020. [Online]. Disponible: <https://arxiv.org/abs/2006.10204>
- [3] T. Chen y C. Guestrin, "XGBoost: A Scalable Tree Boosting System," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 785–794.
- [4] S. Hochreiter y J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [5] F. Angelini, Z. Fu, Y. Long, L. Shao, y S. M. Naqvi, "2D Pose-Based Real-Time Human Action Recognition With Occlusion-Handling," *IEEE Transactions on Multimedia*, vol. 22, no. 6, pp. 1433–1446, 2020.